

Введение

Опишем процедуру построения теории, на которой держится математическая статистика.

В первую очередь в курсе теории вероятностей вводится понятие вероятностного пространства. Это понятие обобщает под одним термином три сущности, позволяющие в дальнейшем исследовать различные теоретические вопросы.

Итак, вероятностным пространством называют тройку

$$(\Omega, \mathcal{F}, P),$$

где Ω — это пространство элементарных исходов (все возможные результаты эксперимента), \mathcal{F} — семейство подмножеств Ω , которые называются событиями, P — функция на событиях (вероятность).

Задание вероятностного пространства означает задание модели физического эксперимента.

С точки зрения теории меры, вероятность P называют еще вероятностной мерой.

В экспериментах мы хотим уметь рассчитывать вероятности событий, которые можно описать числами. Например, температуру в комнате, количество аварий, количество голов в матче и т.д. Поэтому естественно вводится понятие случайной величины.

$$X : \Omega \rightarrow \mathbb{R}$$

Случайная величина X , заданная на пространстве (Ω, \mathcal{F}, P) , задает автоматически свою вероятностную меру, но уже на подмножествах B значений X (по-умному можно так записать $B \subseteq \text{Im } X \subseteq \mathbb{R}$):

$$P_X(B) := P(\omega : X(\omega) \in B) \equiv P(X \in B) \equiv P(X^{-1}(B))$$

То есть каждая случайная величина, как говорят, индуцирует свое вероятностное пространство

$$(\mathcal{X}, \mathcal{F}_X, P_X)$$

Задание P_X называется заданием распределения X .

В задаче математической статистики мы имеем результат некоторого эксперимента. В терминах вероятностного пространства у нас есть исход $\omega \in \Omega$, на котором посчитана некоторая числовая характеристика X . В нашей мат. модели X — это случайная величина (обычно, случайный вектор), про распределение которой мы точно не знаем, но имеем уверенность, что это распределение лежит в некотором семействе распределений \mathcal{P} .

Если это семейство запаараметризовано, т.е. каждому распределению семейства соответствует некоторый числовой параметр $\theta \in \Theta \subseteq \mathbb{R}^k$, то такое семейство называется параметризованным, и тогда задача узнать распределение сводится к задаче узнать параметр распределения.

Таким образом, статистическая модель (статистическое пространство) выглядит следующим образом

$$(\mathcal{X}, \mathcal{F}, \mathcal{P})$$

где \mathcal{X} — множество всех возможных значений X , \mathcal{F} — семейство событий на \mathcal{X} , \mathcal{P} — семейство распределений X .

Оценивание (Estimation)

Выборкой называется набор из n случайных величин X_1, \dots, X_n . Реализацией выборки называется набор чисел $X_1(\omega), \dots, X_n(\omega)$.

Итак, задача статистики заключается в том, чтобы получить какую-либо информацию о распределении по данной выборке X_1, \dots, X_n .

Узнать что-либо о распределении это то же самое, что узнать что-то о его параметре, некую величину $h(\theta)$, где θ — параметр распределения. То есть нам надо, чтобы была функция $\hat{\theta}(x_1, \dots, x_n)$, такая что случайная величина $\hat{\theta}(X_1, \dots, X_n)$ как-то характеризовала величину $h(\theta)$. Тогда $\hat{\theta}(X_1, \dots, X_n)$ называют оценкой $h(\theta)$.

Несмещенность

Встает вопрос, как определить, насколько оценка хороша. Естественно потребовать, чтобы оценка в среднем была равна оцениваемому параметру, то есть, чтобы

$$E_{\theta} \hat{\theta}(X_1, \dots, X_n) = h(\theta)$$

где E_{θ} — математическое ожидание по мере P_{θ} (иначе говоря, для распределения P_{θ}).

Если такое условие выполнено, то оценка $\hat{\theta}$ называется несмещенной для $h(\theta)$.

Квадратичное отклонение

Как для случайных величин важно понятие дисперсии (среднеквадратичного отклонения от среднего), так и для оценок важно понятие квадратичного смещения.

Квадратичным смещением называется

$$E_{\theta} (\hat{\theta}(X_1, \dots, X_n) - h(\theta))^2$$

Для несмещенных оценок квадратичное смещение равно $D_{\theta} \hat{\theta}(X_1, \dots, X_n)$.

Задачи

Задача 1. Пусть $F_{\theta}(x) = 1 - \theta^{x+1}$, $x \in \{0, 1, \dots\}$, $\Theta = (0, 1)$. Построить несмещенную оценку для θ от одного наблюдения.

Решение. Нужно построить оценку $\hat{\theta}(X_1)$, чтобы $E_{\theta} \hat{\theta}(X_1) = \theta$.

Посчитаем математическое ожидание такой оценки в общем виде, а затем попытаемся понять, какой должна быть сама оценка.

$$E_{\theta} \hat{\theta}(X_1) = \sum_{k=0}^{\infty} \hat{\theta}(k) P_{\theta}(X_1 = k) = (*)$$

Найдем $P_{\theta}(X_1 = k)$ из нашей функции распределения.

Так как $F_{\theta}(x) = P_{\theta}(X \leq x)$, то

$$P_{\theta}(X_1 = k) = F_{\theta}(k) - F_{\theta}(k-1) = 1 - \theta^{k+1} - 1 + \theta^k = \theta^k(1 - \theta)$$

Теперь вернемся к подсчету мат. ожидания:

$$(*) = \sum_{k=0}^{\infty} \hat{\theta}(k) \theta^k (1 - \theta) = (1 - \theta) \sum_{k=0}^{\infty} \hat{\theta}(k) \theta^k$$

(воспользовались суммой геом. прогрессии $\sum_{k=0}^{\infty} \theta = \frac{1}{1-\theta}$)

Итак, чтобы оценка $\sum_{k=0}^{\infty} \hat{\theta}(k) \theta^k$ была несмещенной, нужно, чтобы

$$(1 - \theta) \sum_{k=0}^{\infty} \hat{\theta}(k) \theta^k = \theta \Leftrightarrow \sum_{k=0}^{\infty} \hat{\theta}(k) \theta^k = \frac{\theta}{1 - \theta} = \theta + \theta^2 + \theta^3 + \dots = \sum_{k=1}^{\infty} \theta^k$$

Таким образом, мы хотим, чтобы $\hat{\theta}(0) = 0$, а $\hat{\theta}(k) = 1$ для всех $k = 1, 2, \dots$. Отсюда

$$\hat{\theta}(X_1) = I_{X_1 > 0}.$$

Задача 2. а) Найти несмещенную оценку для DX_1 вида cS^2 , где $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, X_i — независимые одинаково распределенные (далее н.о.р.).

б) Найти ее квадратичное смещение в случае $X_i \sim \mathcal{N}(0, \theta)$.

□ Пункт а).

$$\begin{aligned} ES^2 &= \frac{1}{n} \sum_{i=1}^n E(X_i - \bar{X})^2 = \frac{1}{n} \sum (EX_i^2 - 2EX_i\bar{X} + E\bar{X}^2) = \\ &= \frac{1}{n} \sum EX_i^2 - \frac{2}{n} \sum EX_i\bar{X} + \frac{1}{n} \sum E\bar{X}^2 = \\ &= EX_1^2 - 2E\left(\frac{1}{n} \sum X_i\bar{X}\right) + \frac{1}{n} E\bar{X}^2 = \\ &= EX_1^2 - 2E\bar{X}^2 + E\bar{X}^2 = EX_1^2 - E\bar{X}^2 \end{aligned}$$

Теперь посчитаем $E\bar{X}^2$:

$$\begin{aligned} E\bar{X}^2 &= E\left(\frac{X_1 + \dots + X_n}{n}\right)^2 = \frac{1}{n^2} E(X_1^2 + \dots + X_n^2 + 2 \sum_{i < j} X_i X_j) = \\ &= \frac{1}{n^2} (nEX_1^2 + 2C_n^2 (EX_1)^2) = \frac{1}{n} EX_1^2 + \frac{n-1}{n} (EX_1)^2 \end{aligned}$$

Подставляя в предыдущую формулу, получаем, что

$$ES^2 = EX_1^2 - \frac{EX_1^2}{n} - \frac{n-1}{n} (EX_1)^2 = \frac{n-1}{n} (EX_1^2 - (EX_1)^2) = \frac{n-1}{n} EX_1$$

Таким образом, оценка S^2 — смещенная, но оценка $S_0 = \frac{n}{n-1} S^2$ будет несмещенной.

Теперь пункт б). Теперь мы знаем, что $X_i \sim \mathcal{N}(0, \theta)$, то есть $EX_i = 0$, $DX_i = \theta$.

Так как наша оценка несмещенная, то квадратичным смещением будет просто дисперсия DS_0 .

$$DS_0 = ES_0^4 - (ES_0^2)^2 = ES_0^4 - (EX_1)^2 = ES_0^4 = E\left(\frac{n}{n-1} S^2\right)^2 = \frac{n^2}{(n-1)^2} ES^4$$

Для поиска ES^4 воспользуемся тем, что $S^2 = \bar{X}^2 - \bar{X}^2$. тогда

$$\begin{aligned} ES^4 &= E\frac{1}{n^2} (\bar{X}^2 - \bar{X}^2)^2 = \frac{1}{n^2} E(\bar{X}^2 - 2\bar{X}^2 + \bar{X}^4) = \\ &= \frac{1}{n^2} (E()) \end{aligned}$$

■